2-词典分词

目录

2. 词典分词

- **中文分词**：指的是将一段文本拆分为一系列单词的过程，这些单词顺序拼接后等于原文本。
- 中文分词算法大致分为**基于词典规则**与**基于机器学习**这两大派。

2.1 什么是词

- 在基于词典的中文分词中，词的定义要现实得多：**词典中的字符串就是词**。
- 词的性质--**齐夫定律**：一个单词的词频与它的词频排名成反比。

> "Zipf's word frequency law in natural language: A critical review and future directions"

在开始之前，我推荐使用anaconda建立一个虚拟环境。

查看虚拟环境列表：执行以下命令可以列出所有已创建的虚拟环境：

```
conda env list
```

创建新环境：

要创建新环境，可以使用`conda create`命令，指定环境名称和要安装的Python版本（可选）。例如，要创建一个名为`myenv`的新环境，并安装Python 3.8版本，可以执行以下命令：

```
conda create --name myenv python=3.8
```

```
conda install -c conda-forge openjdk python=3.8 jpype1=0.7.0 -y
```

```
pip install pyhanlp
```

查看环境：

```
conda info --envs
```

激活环境：

要在命令行中激活特定的环境，可以使用`conda activate`命令，然后指定要激活的环境名称。例如，要激活名为`myenv`的环境，可以执行以下命令：

```
conda activate myenv
```

卸载环境：

要卸载一个已经存在的环境，可以使用`conda remove`命令，然后指定要卸载的环境名称。例如，要卸载名为`myenv`的环境，可以执行以下命令：

```
conda remove --name myenv --all
```

---

zipf_law.py
PY File
2.0 KB

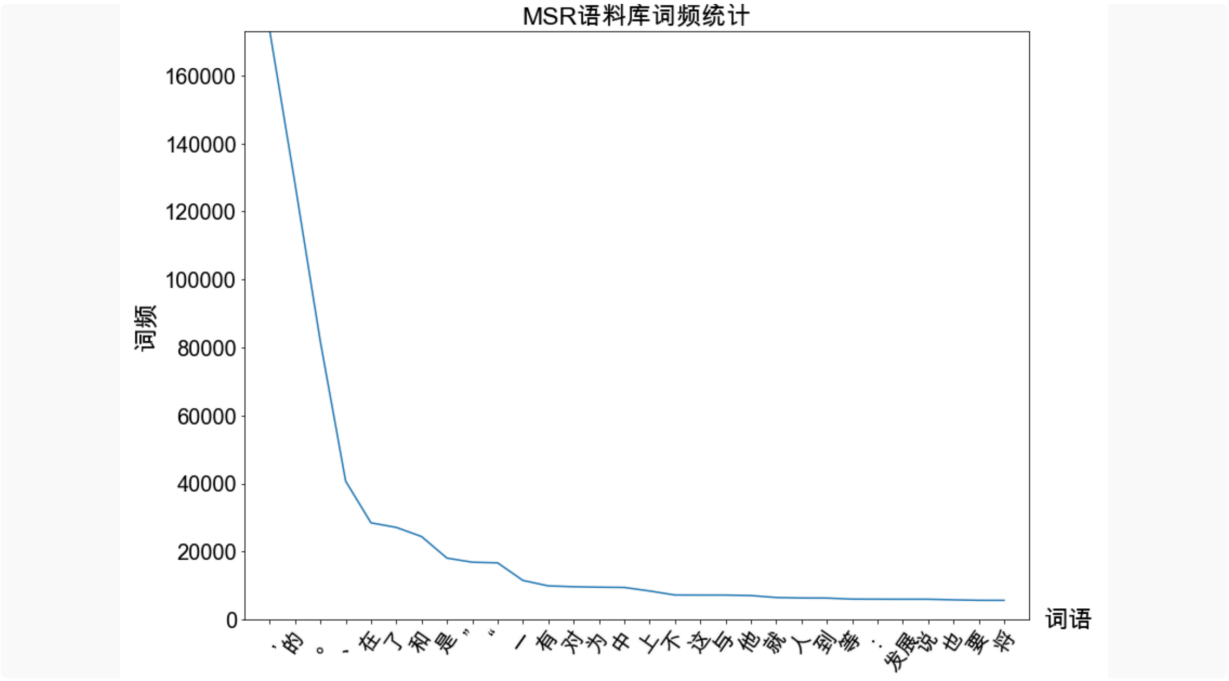

图示大致符合$y = 1/x$ 的幂律分布，或者说二八原则。

> 幂律分布是概率论和统计学中的一种分布形式，也称为长尾分布。这种分布在庞大数据集中很常见，其中很少数目的事件频繁发生，而绝大多数事件只发生很少的次数。幂律分布可以描述大多数现象中的一种特定统计规律，例如互联网上网页链接的数量、城市人口分布、个人财富分布等。在幂律分布中，事件的频率与其排名成反比关系，即排名越靠前的事件发生的频率越高。

2.2 词典

互联网词库(SogouW， 15万个词条)、清华大学开放中文词库(THUOCL)、HanLP词库(千万级词条)

这里以HanLP附带的迷你核心词典为例(本项目路径)：data/dictionnary/CoreNatureDictionary.mini.txt

```
上升v   98  vn  18
上升期   n   1
上升股   n   1
上午t   147
上半叶   t   3
上半场   n   2
上半夜   t   1
```

HanLP中的词典格式是一种以空格分隔的表格形式，第一列是单词本身，之后每两列分别表示词性与相应的词频。

2.3 切分算法

首先，加载词典：

```
def load_dictionary():
    dic = set()

    # 按行读取字典文件，每行第一个空格之前的字符串提取出来。
    for line in open("CoreNatureDictionary.mini.txt","r"):
        dic.add(line[0:line.find(' ')])

    return dic
```

1. **完全切分**

   指的是，找出一段文本中的所有单词。这并不是标准意义上的分词，其主要目标是将一个文本按照单词的划分规则进行分割，得到文本中所有可能的单词。该算法并不考虑单词的语法、语义等信息，仅仅是按照空格、标点符号等规则进行分割。虽然完全切分算法简单，但在一些场景中仍然有一定的应用价值，如在信息检索领域中用于构建倒排索引等。

   ```
   def fully_segment(text, dic):
       word_list = []
       for i in range(len(text)):                  # i 从 0 到text的最后一个字的下标遍历
           for j in range(i + 1, len(text) + 1):   # j 遍历[i + 1, len(text)]区间
               word = text[i:j]                    # 取出连续区间[i, j]对应的字符串
               if word in dic:                     # 如果在词典中，则认为是一个词
                   word_list.append(word)
       return word_list

   dic = load_dictionary()
   print(fully_segment('就读北京大学', dic))
   ```

   输出：

   ```
   ['就', '就读', '读', '北', '北京', '北京大学', '京', '大', '大学', '学']
   ```

   输出了所有可能的单词。由于词库中含有单字，所以结果中也出现了一些单字。

2. **正向最长匹配**

上面的输出并不是中文分词，我们更需要那种有意义的词语序列，而不是所有出现在词典中的单词所构成的链表。比如，我们希望“北京大学”成为一整个词，而不是“北京 + 大学”之类的碎片。具体来说，就是在以某个下标为起点递增查词的过程中，优先输出更长的单词，这种规则被称为**最长匹配算法**。从前往后匹配则称为**正向最长匹配**，反之则称为**逆向最长匹配**。

```
def forward_segment(text, dic):
    word_list = []
    i = 0
    while i < len(text):
        longest_word = text[i]                          # 当前扫描位置的单字
        for j in range(i + 1, len(text) + 1):           # 所有可能的结尾
            word = text[i:j]                            # 从当前位置到结尾的连续字符串
            if word in dic:                             # 在词典中
                if len(word) > len(longest_word):       # 并且更长
                    longest_word = word                 # 则更优先输出
        word_list.append(longest_word)                  # 输出最长词
        i += len(longest_word)                          # 正向扫描
    return word_list

dic = load_dictionary()
print(forward_segment('就读北京大学', dic))
print(forward_segment('研究生命起源', dic))
```

输出：

```
['就读', '北京大学']
['研究生', '命', '起源']
```

第二句话就会产生误差了，我们是需要把“研究”提取出来，结果按照正向最长匹配算法就提取出了“研究生”，所以人们就想出了逆向最长匹配。

3. 逆向最长匹配

```
def backward_segment(text, dic):
    word_list = []
    i = len(text) - 1
    while i >= 0:                                   # 扫描位置作为终点
        longest_word = text[i]                      # 扫描位置的单字
        for j in range(0, i):                       # 遍历[0, i]区间作为待查询词语
的起点
            word = text[j: i + 1]                   # 取出[j, i]区间作为待查询单词
            if word in dic:
                if len(word) > len(longest_word):   # 越长优先级越高
                    longest_word = word
                    break
        word_list.insert(0, longest_word)           # 逆向扫描，所以越先查出的单词在位
置上越靠后
        i -= len(longest_word)
    return word_list

dic = load_dictionary()
print(backward_segment('研究生命起源', dic))
print(backward_segment('项目的研究', dic))
```

输出：

```
['研究', '生命', '起源']
['项', '目的', '研究']
```

第一句正确了，但下一句又出错了，可谓拆东墙补西墙。另一些人提出综合两种规则，期待它们取长补短，称为双向最长匹配。

4. **双向最长匹配**

   这是一种融合两种匹配方法的复杂规则集，流程如下：

   - 同时执行正向和逆向最长匹配，若两者的词数不同，则返回词数更少的那一个。
   - 否则，返回两者中单字更少的那一个。当单字数也相同时，优先返回逆向最长匹配的结果。

```python
def count_single_char(word_list: list):  # 统计单字成词的个数
    return sum(1 for word in word_list if len(word) == 1)


def bidirectional_segment(text, dic):
    f = forward_segment(text, dic)
    b = backward_segment(text, dic)
    if len(f) < len(b):                                    # 词数更少优先级更高
        return f
    elif len(f) > len(b):
        return b
    else:
        if count_single_char(f) < count_single_char(b):  # 单字更少优先级更高
            return f
        else:
            return b                                       # 都相等时逆向匹配优先级更高


print(bidirectional_segment('研究生命起源', dic))
print(bidirectional_segment('项目的研究', dic))
```

> 冒号后面是一个注释，用于说明函数参数的类型。这种语法被称为类型提示（Type Hints）。
> 类型提示并不是强制性的，但它可以提供有用的信息，帮助开发者理解函数的预期输入和输出。类型提示可以在函数参数和返回值后面用冒号表示，然后跟着参数或返回值的类型。在这种情况下，冒号后面的 `list` 表示参数 `word_list` 应该是一个列表，它里面包含的元素的类型是 `list`。这种类型提示的语法形式类似于变量注释。

输出：

```
['研究', '生命', '起源']
['项', '目的', '研究']
```

通过以上几种切分算法，我们可以做一个对比：

序号	原文	正向最长匹配	逆向最长匹配	双向最长匹配
1	项目的研究	[项目, 的, 研究]	[项, 目的, 研究]	[项, 目的, 研究]
2	商品和服务	[商品, 和服, 务]	[商品, 和, 服务]	[商品, 和, 服务]
3	研究生命起源	[研究生, 命, 起源]	[研究, 生命, 起源]	[研究, 生命, 起源]
4	当下雨天地面积水	[当下, 雨天, 地面, 积水]	[当, 下雨天, 地面, 积水]	[当下, 雨天, 地面, 积水]
5	结婚的和尚未结婚的	[结婚, 的, 和尚, 未, 结婚, 的]	[结婚, 的, 和, 尚未, 结婚, 的]	[结婚, 的, 和, 尚未, 结婚, 的]
6	欢迎新老师生前来就餐	[欢迎, 新, 老师, 生前, 来, 就餐]	[欢, 迎新, 老, 师生, 前来, 就餐]	[欢, 迎新, 老, 师生, 前来, 就餐]

上图显示，双向最长匹配的确在2、3、5这3种情况下选择出了最好的结果，但在4号句子上选择了错误的结果，使得最终正确率 3/6 反而小于逆向最长匹配的 4/6， 由此，规则系统的脆弱可见一斑。规则集的维护有时是拆东墙补西墙，有时是帮倒忙。

2.4 字典树

匹配算法的瓶颈之一在于如何判断集合(词典)中是否含有字符串。如果用有序集合TreeMap)的话，复杂度是o(logn) (n是词典大小);如果用散列表(Java的HashMap. Python的dict)的话，账面上的时间复杂度虽然下降了，但内存复杂度却上去了。有没有速度又快、内存又省的数据结构呢？这就是**字典树**。

1. **什么是字典树**

   字符串集合常用字典树(trie树、前缀树)存储，这是一种字符串上的树形数据结构。字典树中每条边都对应一个字， 从根节点往下的路径构成一个个字符串。字典树并不直接在节点上存储字符串， 而是将词语视作根节点到某节点之间的一条路径，并在终点节点(蓝色) 上做个标记"该节点对应词语的结尾"。字符串就是一 条路径，要查询一个单词，只需顺着这条路径从根节点往下走。如果能走到特殊标记的节点，则说明该字符串在集合中，否则说明不存在。一个典型的字典树如下图所示所示。

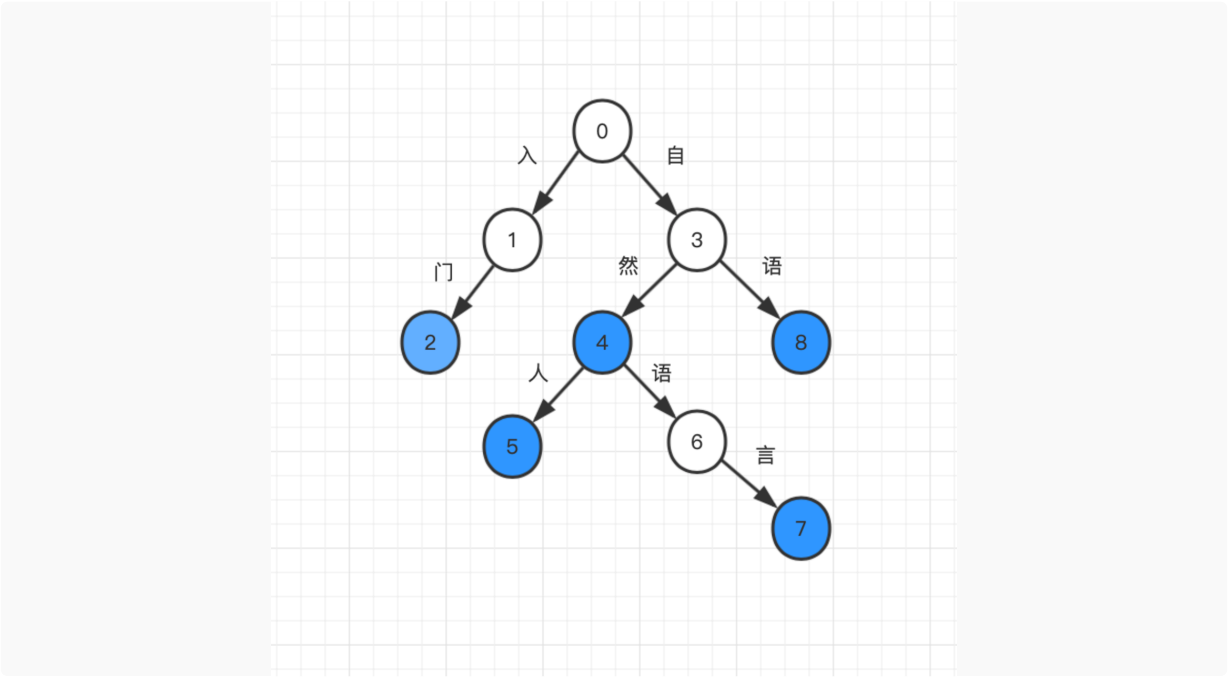

其中，蓝色标记着该节点是一个词的结尾，数字是人为的编号。按照路径我们可以得到如下表所示：

词语	路径
入门	0-1-2
自然	0-3-4
自然人	0-3-4-5
自然语言	0-3-4-6-7
自语	0-3-8

当词典大小为 n 时，虽然最坏情况下字典树的复杂度依然是O(logn) (假设子节点用对数复杂度的数据结构存储，所有词语都是单字)，但它的实际速度比二分查找快。这是因为随着路径的深入，前缀匹配是递进的过程，算法不必比较字符串的前缀。

2. **字典树的实现**

   由上图可知，每个节点都应该至少知道自己的子节点与对应的边，以及自己是否对应一个词。如果要实现映射而不是集合的话，还需要知道自己对应的值。我们约定用值为None表示节点不对应词语，虽然这样就不能插入值为None的键了，但实现起来更简洁。那么字典树的实现参见项目路径(与书上略有不同，我写的比较简洁)：**code/ch02/trie.py**

   通过**debug运行 trie.py 代码**，可以观察到 trie 类的字典树结构：

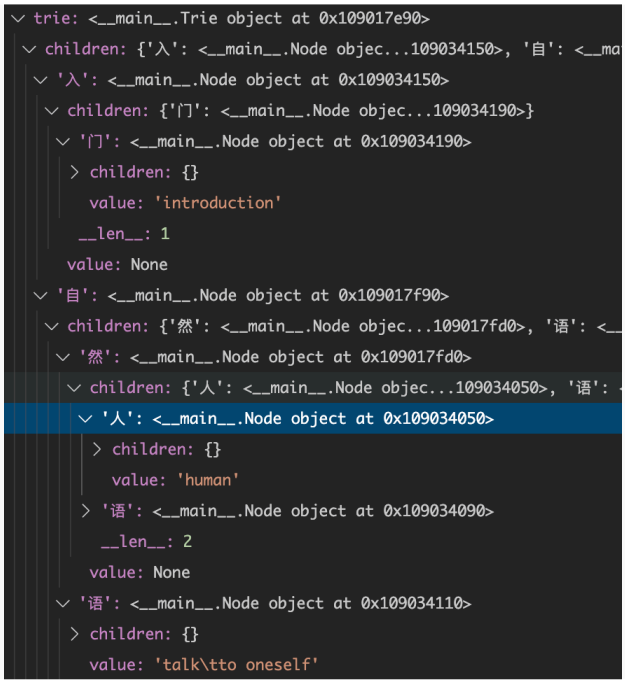

2.5 基于字典树的其它算法

字典树的数据结构在以上的切分算法中已经很快了，但厉害的是作者通过自己的努力改进了基于字典树的算法，把分词速度推向了千万字每秒的级别，这里不一一详细介绍，详情见书，主要按照以下递进关系优化：

- 首字散列其余二分的字典树
- 双数组字典树
- AC自动机(多模式匹配)
- 基于双数组字典树的AC自动机

2.6 HanLP的词典分词实现

1. **DoubleArrayTrieSegment**

   DoubleArrayTrieSegment分词器是对DAT最长匹配的封装，默认加载hanlp.properties中CoreDictionaryPath制定的词典。

```
from pyhanlp import *

# 不显示词性
HanLP.Config.ShowTermNature = False

# 可传入自定义字典 [dir1, dir2]
segment = DoubleArrayTrieSegment()
# 激活数字和英文识别
segment.enablePartOfSpeechTagging(True)

print(segment.seg("江西鄱阳湖干枯，中国最大淡水湖变成大草原"))
print(segment.seg("上海市虹口区大连西路550号SISU"))
```

输出：

```
[江西, 鄱阳湖, 干枯, ，, 中国, 最大, 淡水湖, 变成, 大草原]
[上海市, 虹口区, 大连, 西路, 550, 号, SISU]
```

2. **去掉停用词**

停用词词典文件：data/dictionnary/stopwords.txt

该词典收录了常见的中英文无意义词汇(不含敏感词)，每行一个词。

```
def load_from_file(path):
    """
    从词典文件加载DoubleArrayTrie
    :param path: 词典路径
    :return: 双数组trie树
    """
    map = JClass('java.util.TreeMap')()  # 创建TreeMap实例
    with open(path) as src:
        for word in src:
            word = word.strip()  # 去掉Python读入的\n
            map[word] = word
    return JClass('com.hankcs.hanlp.collection.trie.DoubleArrayTrie')(map)


## 去掉停用词
def remove_stopwords_termlist(termlist, trie):
    return [term.word for term in termlist if not trie.containsKey(term.word)]


trie = load_from_file('stopwords.txt')
termlist = segment.seg("江西鄱阳湖干枯了，中国最大的淡水湖变成了大草原")
print('去掉停用词前：', termlist)

print('去掉停用词后：', remove_stopwords_termlist(termlist, trie))
```

输出：

```
去掉停用词前： [江西, 鄱阳湖, 干枯, 了, ，, 中国, 最大, 的, 淡水湖, 变成, 了, 大草原]
去掉停用词后： ['江西', '鄱阳湖', '干枯', '中国', '最大', '淡水湖', '变成', '大草原']
```